

PRIMENA, SERVIRANJE I MONITORING MODELA MAŠINSKOG UČENJA

Tehnologije i alati u mašinskom učenju

Profesorka: dr Jelena Slivka
Asistent: Dragan Vidaković

Student: Nemanja Ljubičić

MONITORING: TRENUTNE PRAKSE I OGRANIČENJA

- Empirijska studija, sa različitim fokus grupama, veličinama kompanija i profilu zaposlenih.*
- Opisuje se tihi otkaz sistema mašinskog učenja, a kao glavni uzrok navodi se data drift, koji može doći od internih ili spoljnih uzroka.
- Kako se ovi timovi nose sa tim:
 - Validacija kroz ishode, prate se biznis metrike i koriste kao validacija.
 - Detekcija kroz instrumentaciju (uglavnom metrike predikcije).
 - Lokalizacija greške praćenjem unazad (neki imaju grafove zavisnosti).
 - Istorija izmena: koja izmena je izazvala kvar.
- Glavni nalaz: postoje alati za monitoring ali ne hvataju pun kontekst.

*J. Leest, I. Gerostathopoulos, P. Lago, and C. Raibulet, "Monitoring and Observability of Machine Learning Systems: Current Practices and Gaps," arXiv:2510.24142, 2025.

MONITORING: CALM FRAMEWORK

- CALM (Continuous, Adaptive, LLM-Mediated) je framework za detekciju anomalija u realnom vremenu u problemima vremenskih serija.**
- Radi u zatvorenoj petlji:
 - *Time series* model daje predikciju.
 - Ako se detektuje odstupanje od predikcije (statistički), to je anomalija.
 - LLM rasuđuje: KEEP (dotreniranje kada se skupi dovoljan broj KEEP uzoraka) ili REMOVE (anomalija nije od značaja, odbacuje se), sa *confidence* skorom i obrazloženjem.
- Problem iz prvog rada bio je data drift i oslanjanje na čoveka da razlikuje pravu promenu od lažne uzbune. CALM to automatizuje tako što LLM zamenjuje čoveka-analitičara.

**A. Devireddy and S. Huang, "CALM: A Framework for Continuous, Adaptive, and LLM-Mediated Anomaly Detection in Time-Series Streams," arXiv:2508.21273, 2025.

MODEL

- Random Forest model za klasifikaciju vina na dobro i loše.
- Korišćen je *Wine Quality* dataset gde su ocene pretvorene u dve klase.
- Podela na trening-validacioni-test skup
- Ciljna metrika je *Precision* (kako loše vino ne bi bilo klasifikovano kao dobro i time korisnik razočaran).
- Pored *Precision* prate se i *Recall* i ROC-AUC skor.
- Hiperparametri (`n_estimators`, `max_depth`, `min_samples_leaf`, `max_features`, `max_leaf_nodes`) pretraženi su Optuna bibliotekom.
- Procena originalnog modela na validacionom skupu i dobijanje njegove veličine (`max_velicina`).

PRUNNING MODELA

- Nova pretraga parametara, sa suženim opsegom, dodatnim parametrom *ccp_alpha*, koji kontroliše odsecanje stabla.
- Formulisana je funkcija cilja:

$$\text{score} = \text{precision} - \alpha * (\text{velicina} / \text{max_velicina})$$

- *Score* se maksimizuje. Njegova vrednost raste sa porastom *precision*, a opada sa porastom veličine modela.
- Vrš se 100 trials-a pretrage za svaki *alpha* iz opsega [0,1] sa korakom 0.1 tj ukupno 11 vrednosti *alpha*.
- Ručno je odabran model koji ima najbolje metrike na validacionom skupu, uz značajno smanjenje veličine (*alpha* = 0.4).

POREĐENJE MODELA

- Treniranje originalnog modela sa njegovim najboljim parametrima, na trening + validacionom skupu. Procena na test skupu. Ispis metrika i veličine.
- Treniranje prunovanog modela sa njegovim najboljim parametrima i *alpha* na trening + validacionom skupu. Procena na istom test skupu. Ispis metrika i veličine.

Model	Precision	Recall	ROC-AUC	Veličina (KB)
Originalni	0.7458	0.6875	0.8363	625.5
Prunovan	0.7627	0.7031	0.8068	19.9
Promena (%)	+2.27	+2.27	-3.53	-96.8

Odabran za primenu

TOK SISTEMA

1. Pokretanje servera: FAST API i učitavanje modela.
2. Pristizanje zahteva: Frontend čita 11 unetih obeležja. Šalje se FAST API-ju koji ga mapira na ulazni format koji model očekuje.
3. Validacija ulaza: Ako je zahtev prošao Pydantic pravila (tip promenljive i opseg), prosleđuju se modelu. U suprotnom, ispisuje se poruka o nepravilnom unosu i traži se ponovni unos.
4. Za ispravne ulaze, vrednosti se pakuju u niz od 11 elemenata (11 ulaznih obeležja).
5. Poziv modela i prosleđivanje ulaza.
6. Provera da li je izlaz $[0,1]$:
 - Ukoliko jeste, proverava se da li sigurnost modela viša od praga (0.55):
 - Ako jeste, vraća se labela i sigurnost.
 - Ako je niska sigurnost, vraća se labela, sigurnost i ispis niske sigurnosti
 - Ako nije u očekivanom opsegu, to je ozbiljna greška, korisniku se ne vraća izlaz.
7. Praćenje latencije i drifta na svakih 100 zahteva.

FORMA I ISHODI

Predikcija kvaliteta vina

Fiksna kiselost

7.4

Isparljiva kiselost

0.70

Limunska kiselina

0.00

Preostali šećer

1.9

Hloridi

0.076

Slobodni SO₂

11

Ukupni SO₂

34

Gustina

0.9978

pH vrednost

3.51

Sulfati

0.56

Procenat alkohola

9.4

Proceni kvalitet vina

DOBRO VINO

Model je 79.6% siguran da je ovo dobro vino

LOSE VINO

Model je 67.3% siguran da je ovo lose vino

DOBRO VINO

Model nije dovoljno siguran, 54.5% sigurnosti. Uzmite ovaj rezultat sa rezervom.

Ukupni SO₂

500


Unos nije ispravan. Primer tačnog unosa: 34 (opseg: 0.001 - 300)

TESTIRANJE

- Skripta koja šalje upite ka servisu.
- Šalje 1000 zahteva u tri faze:
 - 800 validnih, sa vrednostima obeležja koja su viđena tokom treninga.
 - 100 validnih, sa vrednostima obeležja čije su vrednosti van opsega viđenog tokom treninga, ali i dalje fizički moguće.
 - 100 nevalidnih, sa pogrešnim tipom promenljive ili vrednosti van fizički mogućeg opsega
- Nakon svakog uspešnog zahteva broji se koliko je takvih zahteva ukupno bilo.
- Na svaki 100-ti, automatski se pokreću dve provere:
 - Drift podataka: poslednjih 100 uzoraka simulira data drift, u ovom slučaju pojavu novog vina sa većim procentom alkohola i promenjenim vrednostima gustine, sulfata i pH vrednosti. Evidently biblioteka (Kolmogorov-Smirnov test) poredi poslednjih 100 zahteva sa originalnim trening skupom i generiše izveštaj.
 - Latencija: merenje *response vremena* i *round trip* vremena.
- Logovanje: jedna zajednička SQLite baza sa 4 tabele, razdvojene po funkciji.

LATENCIJA

- Latencija: mere se dva vremena prikazana na slici. *Response* vreme se odnosi na obradu na serveru (najviše poziv modela, ali i pripremu podataka i računanje rezultata), dok se *round trip* vreme odnosi na ceo tok od slanja zahteva do dobijanja odgovora, uključujući mrežu.



REZULTATI

- Vrednosti *response* vremena i *round trip* vremena.
- *Response* se prikazuje samo za uspešne/nesigurne predikcije (900). Namerno se izostavljaju validacione greške i eventualne anomalije, da bi brojka predstavljala tipičnu performansu, a *round trip* vreme se računa za svih 1000.
- Posebno važna veličina je **P95**, jer ona govori da će 95% korisnika imati to vreme obrade ili niže.

Response vreme statistika


Broj uzoraka	900
Minimum (ms)	3.00
Medijana (ms)	8.00
Prosek (ms)	12.46
P95 (ms)	26.11
Maksimum (ms)	386.81


Round trip vreme statistika

Broj uzoraka	1000
Minimum (ms)	12.90
Medijana (ms)	70.01
Prosek (ms)	78.07
P95 (ms)	124.71
Maksimum (ms)	1534.47

REZULTATI

- *Evidently* je generisao izveštaje o driftu, zato drift nije zasebno logovan u neku od tabela.
- Na svakih 100 validnih upita se proveravao drift, pa postoji 9 izveštaja
- Kako su drift uzorci u poslednjih 100 zahteva, gleda se poslednji izveštaj.



Column	Type	Reference Distribution	Current Distribution	Data Drift	Stat Test	Drift Score
> chlorides	num			Not Detected	K-S p_value	0.965102
> alcohol	num			Detected	K-S p_value	0

REZULTATI

- Može se analizirati raspodela labela za različite grupe uzoraka.
- Primećuje se da model svim uzorcima sa driftom dodeljuje labelu dobro vino. Svi ovi uzorci imaju oznaku *success*. Bez praćenja drifta, ova pojava ne bi imala objašnjenje.
- Alkohol i sulfati (pozitivno korelisani) su povećani, gustina (negativno korelisana) je smanjena pa sve troje guraju predikciju ka 'dobro vino'. pH je uključen, ali njegova korelacija je zanemarljiva pa ne utiče značajno na ishod.

Raspodela labela	Dobro/loše vino
U dataset-u	855/744
Kada nema data drift-a	63/37
Kada postoji data drift	100/0

Drift-ovana obeležja	Korelacija sa izlazom
Alkohol	0.43
Gustina	-0.16
Sulfati	0.21
pH	-0.01

MOGUĆNOSTI POBOLJŠANJA

- Uvesti *fallback* metode, gde se umesto trenutnog ispisa korisniku, poziva drugi, rezervni model ili se prelazi na heuristiku (pravilo zasnovano na poznatim zavisnostima između obeležja i ciljne promenjive).
- Sistem obaveštavanja, koji u slučaju pomenutih anomalija šalje alarm (npr. imejl). Sada se samo upisuju u posebnu tabelu.
- Simulacija realnog saobraćaja, koja bi dala pun uvid u latenciju. Sada se zahtevi šalju jedan za drugim, sa razmakom između. Uvesti i paralelne zahteve.

HVALA NA PAŽNJI!